

Curso de especialización en Inteligencia Artificial y Big Data

UD04. DESARROLLO DE APLICACIONES DE IA: ALGORITMOS

Carlos Sáenz Adán

1. Algoritmos y modelos predefinidos

Originariamente, la IA pretendía centrarse en aspectos cognitivos, como eran la lógica del razonamiento humano o el modelado del conocimiento. Paralelamente a esta corriente, surgió otra que pretendía centrarse en el Reconocimiento de Patrones, que tenía que ver con una componente más perceptiva, relacionada con los sentidos: la visión, el habla, etc. Así, se propusieron aplicaciones relacionadas con el reconocimiento de figuras, la detección de patrones lingüísticos, etc. Con el fin de integrar ambas corrientes, y alguna más, surgió el Aprendizaje Automático o Machine Learning. Para entender el Aprendizaje Automático es necesario prestar atención a los mecanismos de aprendizaje que usa un sistema inteligente para resolver un problema. Todo proceso de aprendizaje generalmente parte una serie de datos de aprendizaje o entrenamiento que suelen consistir en unos datos de entrada X y unos de salida Y . El proceso de aprendizaje consiste en encontrar el modelo $F : X \rightarrow Y$ que generalice los datos. Normalmente el proceso de “generalizar” simplemente consiste en predecir la salida Y .

En este caso, hay dos grandes tipos de razonamiento:

- **Deductivo:** Se parte de una serie de instrucciones supervisadas por un experto. De ahí se define una serie de reglas generales que permiten obtener conclusiones particulares. En estos casos se especifican mecanismos causales en la construcción del modelo F . Un ejemplo de estas técnicas es el razonamiento basado en casos que es usado en los **sistemas expertos**. Los sistemas expertos son un modelo de IA que intenta imitar el comportamiento de un ser humano experto en algún dominio concreto.
- **Inductivo:** En este caso se parte de una serie de datos, porque el conocimiento a priori sobre el problema a resolver es escaso. Esos datos se interpretan como ejemplos o muestras para el aprendizaje de cuál es la salida del sistema para cada entrada. Es necesario desarrollar modelos que analicen dichos ejemplos concretos, los expliquen y permitan llevar a cabo una generalización de los mismos. En estos casos los modelos F actúan como cajas negras, reciben unos datos y generan una salida, por lo que son candidatos a ser “predefinidos” por plataformas de IA como se verá más adelante, dado que el usuario no debe tener gran conocimiento de lo que ocurre en el sistema, “simplemente” se les dota de una serie de datos y el sistema genera, por sí solo, la salida. Este es el mecanismo de razonamiento por excelencia del Aprendizaje Automático. Algunos ejemplos típicos de estos modelos son las redes neuronales o los árboles de decisión.

Existen otros tipos de razonamiento dependiendo de la cantidad de información que se tiene de los datos de entrenamiento. La información puede estar completa o incompleta:

- **Supervisado:** La información está completa, las observaciones son dadas mediante sus datos de entrada X y sus datos de salida Y . Dada una colección de datos previamente clasificados, estos se

utilizan para entrenar un algoritmo que será capaz de aprender sus estructuras típicas, para posteriormente clasificar cualquier otro dato. Entre los algoritmos típicos pueden encontrarse los Support Vector Machines, clasificadores naive Bayes, distintos tipos de regresiones, árboles de decisión, etc.

- No supervisado: La información está incompleta, por ejemplo, se conoce la entrada X pero no la salida Y. Conseguir grandes colecciones de datos previamente clasificados para entrenar un algoritmo es una tarea compleja, por lo que, en aquellos casos en los que la información no está completa, existe este otro tipo de algoritmos que intentan analizar la estructura interna de los datos, diferenciar entre ellos e inferir a qué clases/grupos podrían pertenecer o no. Los algoritmos típicos son los algoritmos de *clustering*, análisis de componentes principales (PCA en inglés), Singular Value Decomposition (SVD) o el análisis de componentes independientes.
- Semisupervisado: Es una combinación de los dos anteriores, hay colección previa de datos, en la que algunos están clasificados pero, otros no.

Debes saber...

En el siguiente vídeo tenéis una explicación muy ilustrativa del aprendizaje supervisado y no supervisado.

<https://www.youtube.com/watch?v=oT3arRRB2Cw>

Existen más tipos de mecanismos de razonamiento:

- Aprendizaje adaptativo: Se parte de un modelo previo cuyos parámetros se van modificando/adaptando en función de nuevos datos de entrenamiento que van entrando en el sistema.
- Aprendizaje activo: Se conoce la entrada X pero no la salida Y. El sistema debe seleccionar cuáles son los mejores datos de las observaciones y estos, los usa para que un humano los etiquete, generando la salida Y.
- Aprendizaje por refuerzo: Puede considerarse como un caso de aprendizaje semi-supervisado. Los algoritmos se marcan una serie de objetivos y reciben recompensas (premios o castigos) según vayan prediciendo las salidas. En esta estrategia de aprendizaje, mediante ensayo y error, el programa itera de forma muy rápida, aprovechando normalmente las capacidades de supercomputadores, generando múltiples opciones hasta detectar cuál es la opción ganadora, es decir, la que alcanza el objetivo, ganando la recompensa. Es una estrategia ampliamente utilizada en el

mundo de los juegos, siendo su máximo representante el programa que juega al ajedrez AlphaZero de DeepMind Technologies, actualmente absorbida por Alphabet, empresa matriz de Google. Esto supone una explosión de combinaciones que intentan predecir cuál será el desarrollo de una partida de ajedrez por ejemplo, suponiendo los movimientos de ambos jugadores. Mediante el análisis de todas posibilidades, el sistema trata de aprender caminos, patrones, sacar conclusiones o resultados, que le permitan desarrollar la partida con una estrategia ganadora. Normalmente, algunos algoritmos utilizados en esta categoría son los de programación dinámica, Q-Learning y SARSA (state-action-reward-state-action).

Prestando especial atención al razonamiento supervisado o no supervisado, las aplicaciones típicas del Aprendizaje Automático que pueden encontrarse son:

Clasificación

El objetivo es predecir la salida Y, también puede ser denominada como clase o etiqueta, a partir de los datos de entrada X. Pueden encontrarse distintos tipos de clasificaciones según el número de valores de salida:

- *Clasificación binaria*: Solo hay dos clases que detectar, por ejemplo, positivo o negativo, o mujer u hombre.
- *Clasificación multi-clase*: Existen más de dos clases que detectar. Por ejemplo, un tweet puede ser clasificado como positivo, negativo o neutro.
- *Clasificación multi-etiqueta*: Cada dato puede ser etiquetado con varias clases, no solo una. Si se analizaran los mensajes de texto de una persona para estudiar su personalidad, diversas etiquetas/clases podrían ser asignadas: extrovertida y agresiva, introvertida y simpática, etc.

Clustering

El clustering es una opción cuando el conjunto de datos de entrenamiento es incompleto, y la salida no es conocida. Bajo estas circunstancias, el proceso básicamente consiste en la búsqueda de patrones repetitivos dentro de los datos, es decir, buscar subconjuntos de datos similares entre sí de acuerdo a las características de la entrada X.

Regresión


Es un caso similar al de la clasificación pero la variable de salida no es una etiqueta o clase, es decir, una variable categórica (alto-bajo, positivo- negativo, bueno-regular-malo, etc.). El objetivo de este tipo de problemas es la predicción del valor de una variable continua Y, por ejemplo, la altura de una persona, dados unos valores de entrada X, que representarán características sobre esta persona: peso, ejercicio diario, características físicas de sus padres, etc.

2. Definición de modelos

Las técnicas de Aprendizaje Automático se basan principalmente en la definición de un **modelo** matemático M que representa la realidad R del problema a resolver. Cada realidad depende de quién la observa, es decir, cada persona u observador puede ver distintos problemas o preguntas que resolver respecto a la realidad. Así, un modelo M es un modelo matemático en un dominio o realidad R para un observador O , que debe:

1. Responder a las preguntas de un observador acerca de la realidad R .
2. Generar datos que reproduzcan la realidad R partiendo de las observaciones de que se dispone de la realidad o dominio R .

Por ejemplo, en la siguiente figura veremos una representación de una persona con experiencia que clasifica paquetes que pasan por una cinta transportadora.



La realidad o dominio R es ese proceso de clasificación manual de los paquetes de la cinta. El observador necesita automatizar ese proceso de clasificación, por lo que sus observaciones son, para cada paquete, las clases en las que son clasificados por el humano. El proceso cerebral que lleva el humano para tomar la decisión de, en qué clase categoriza cada paquete es un misterio, es decir, es una caja negra a la cual no se puede acceder. Así, la única información que se tiene son las observaciones que toma el observador, es decir, los datos. Datos puede haber muchos, el tamaño del paquete, el color, la forma, pero solo deben observarse aquellos que pueden ser útiles para entender el proceso de clasificación.




Un modelo matemático debe intentar simular el comportamiento del humano, es decir, responder a la pregunta, dado un paquete, a qué categoría corresponde, pero como puede observarse, la función no consiste en reproducir la forma de funcionamiento del cerebro humano, sino simplemente replicar las observaciones que se han obtenido.

En resumen, el cerebro humano es una caja negra que depende de los datos de entrada X para producir una salida Y , formalmente, $\text{cerebro}(X) = Y$.

A través del siguiente enlace puedes acceder a una explicación ilustrada de qué son los modelos.

<https://www.youtube.com/watch?v=Sb8XVheowVQ>

3. Bibliografía

-  Aurélien Géron. Aprende Machine Learning con Scikit-Learn, Keras y TensorFlow. O'Reilly.
-  Peter Bruce, Andrew Bruce y Peter Gedeck. Estadística práctica para ciencia de datos con R y Python. Marcombo.
-  Materiales formativos FP Online del Ministerio de Educación y Formación Profesional. Módulo de Programación de Inteligencia Artificial.